R 기초 프로그래밍

한국환경정책·평가연구원
부연구위원 진대용

강의자료 : https://github.com/dyjin1217

프로그래밍 언어

- 사람과 컴퓨터 사이에 존재하는 일종의 의사소통 수단
  - 컴퓨터한테 명령을 내리기 위한 수단

출처 : https://istudio7.tistory.com/46

R 프로그램

- R은 통계 계산과 그래픽을 위한 **프로그래밍 언어**이자 소프트웨어 환경 (위키피디아)
- R의 활용
  - 통계분석
  - 기계학습
  - 네트워크 분석
  - 웹 프로그램
  - 유전체 분석
  - …

R 프로그램 장/단점

- 장점
  - 다양한 패키지
  - 시각화
  - 무료 (오픈 소프트웨어)
- 단점
  - 느림
  - 높은 메모리 요구
- 그 외
  - 유연성 (예 : 데이터 타입)

R 프로그램 설치

- R 설치
  - https://www.r-project.org
- R-studio 설치
  - https://www.rstudio.com/
  - 통합개발환경 : 개발에 관련된 모든 작업을 하나의 프로그램 안에서 처리하는 환경
- 참조 사이트
  - https://backgomc.tistory.com/34

R-Studio 시작화면

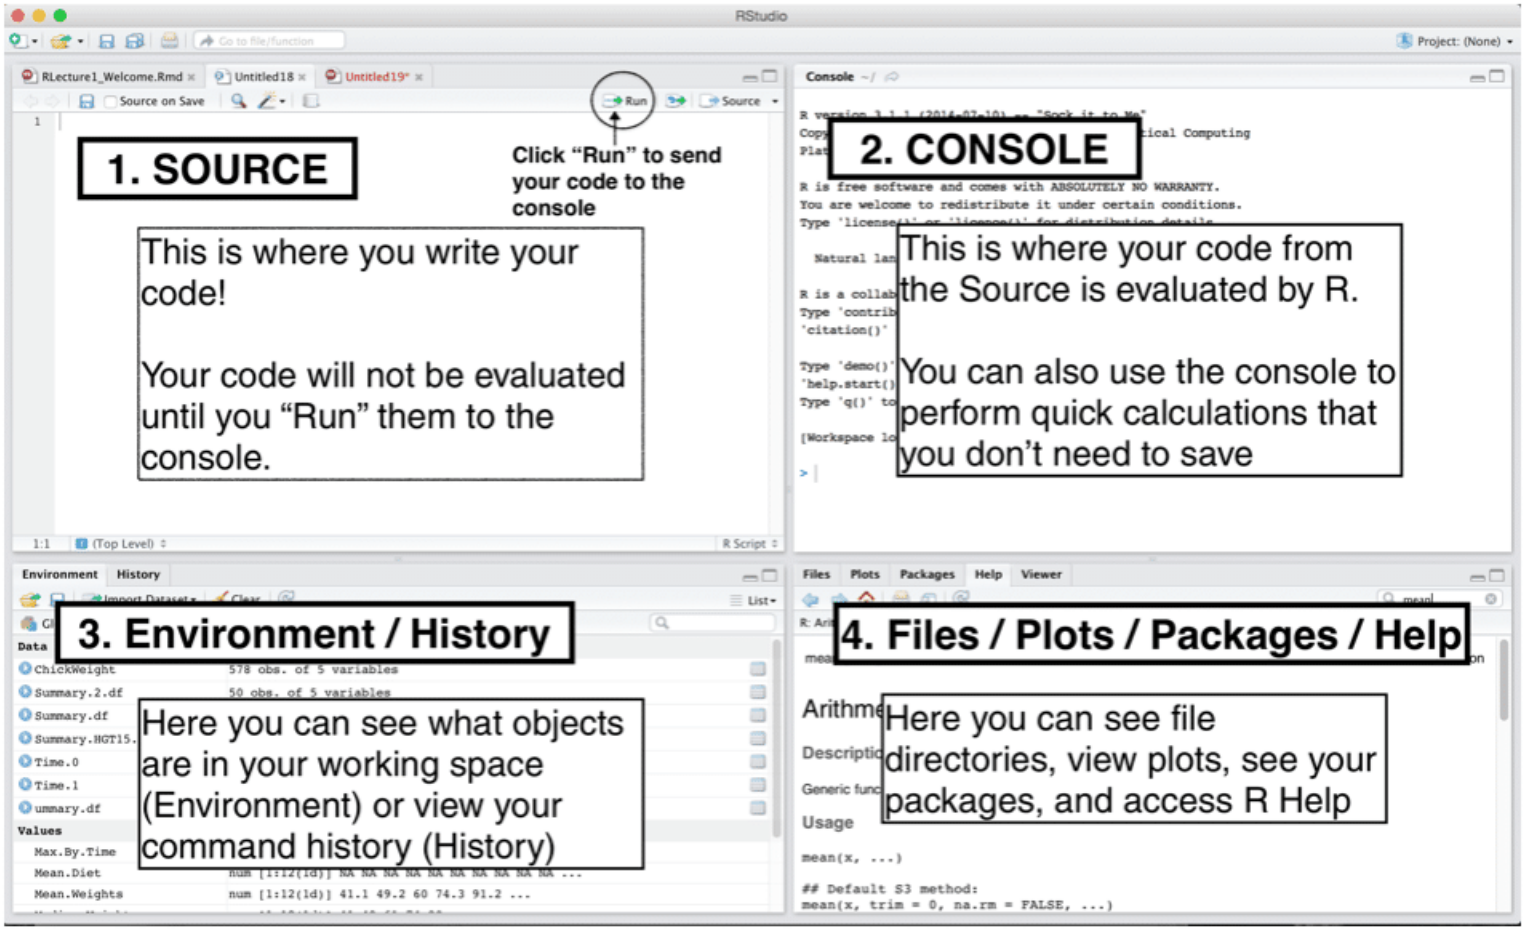

https://datascienceplus.com/introduction-to-rstudio/

첫 프로그래밍

- 2 + 3
- “Hello World”
- X <- 3
- X * X

R의 연산

- 산술 연산 (+,-,/,%%,^...)
  - 3 + 2, X + 2
- 논리 연산 (AND(&), OR(|), NOT(!)...)
  - X %% 2 == 0 & X %% 3 == 0
- 비교(관계) 연산 (>, <, ==, ...)
  - X > 2
  - X == 3
- 대입/할당 (연산)
  - X <- 3 (기본)
  - X = 3 (함수에서 주로 사용)

R 데이터 타입

기본 데이터 타입 (원자 벡터)

객체(변수)	예
integer	100
double	0.05
character	"Hello"
logical	TRUE
factor	"Black"

데이터 타입(자료의 형태)

Vector

Matrix

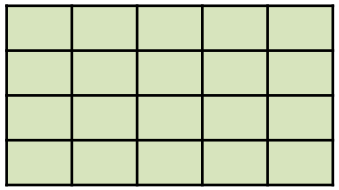

Data frame

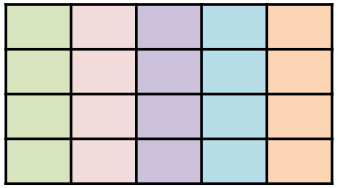

List

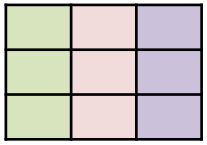

"R에서 모든 객체(변수)는 데이터 타입(자료의구조)를 가지고, 기본이 되는 데이터 타입은 벡터(Vector)"

R 데이터 타입

- 벡터(vector)
  - 1차원 데이터, 동일 데이터 타입
- 행렬(matrix)
  - 2차원 행*열 데이터, 동일 데이터 타입
- 데이터 프레임(dataframe)
  - 2차원 행*열 데이터, 열 단위 다른 데이터 가능
- 리스트(list)
  - 다수 객체를 인덱스를 활용하여 사용

R 데이터 타입 연습

- 연습
  - A <- 3
  - A <- 4.5
  - A <- “안녕”
  - A <- c(1,2,3)
  - A <- c(“사과”,”바나나”,”배”)
  - A <- matrix(c(1,2,3,4), nrow=2)
  - A <- data.frame(숫자=c(1,2,3),과일= c("사과","바나나","배"))

데이터 타입 알아보기

- typeof(객체)
  - 기본 데이터 타입을 출력
- class(객체)
  - 객체의 종류 출력, 벡터는 기본 데이터 타입을 출력
- str(객체)
  - 객체구조 출력

데이터 타입 확인 및 변경

- is.character(객체)
  - is.character(c(1,2)) # FALSE
- as.character(객체)
  - as.character(c(1,2))

- as.matrix(객체)
  - A <- as.matrix(c(1,2,3,4))
- as.vector(객체)
  - A <- as.vector(A)

벡터 생성

- 1~5 벡터 생성
  - A <- c(1,2,3,4,5)
  - A <- 1:5
  - A <- seq(1,5,1) # seq(시작값, 끝값, 등차)
- 5가 5번 벡터 생성
  - A <- rep(5,5) # rep(숫자, 반복횟수)

벡터 원소 추출

- R의 인덱스는 1부터 시작
  - 예 : 1번째 원소는 인덱스 1
- 인덱스 기반 벡터 원소 추출
  1. A <- 1:10
  2. A[3] : 3번째 원소 추출 #A[인덱스]
  3. A[1:3] : 1~3번째 원소 추출 # A[시작인덱스:끝인덱스]
  4. A[5:10] : 5번째 원소부터 끝까지 출력 # A[시작인덱스:]
  5. A[1:2] : 2번째 원소까지 출력 # A[:끝인덱스]
  6. A[-1] : 1번째 인덱스 제외
  7. A[-(1:3)] : 1번째 인덱스 제외

벡터 원소 추출

- 값 기반 원소 추출
  - A <- c(1,3,5,3,2,5,3)
  - A == 3
  - A[A==3]
  - A[A>3]
  - A %in% c(3,5)
  - A[A %in% c(3,5)]

행렬 생성 및 추출

- 1~4 2 × 2 행렬 생성
  1. V <- c(1,2,3,4)
  2. A <- matrix(V, nrow=2, byrow=2)
- 1~25사이 숫자 생성 및 5*5 행렬 생성
  1. V <- 1:25
  2. A <- matrix(V, nrow=5) # matrix(데이터(벡터), 행,열)
  3. A[3,3] # 3,3
  4. A[1:3,4:5] #1~3행, 4~5열 추출
  5. A[,4:5] #모든행 4~5열 추출
  6. A[-1,] #행 제외 추출
  7. A[,-(2:3)] # 2~3열 제외 추출

데이터 프레임 생성 및 추출

- 2개 다른 기본타입의 벡터를 데이터프레임으로
  1. A <- data.frame(숫자=c(1,2,3),과일= c("사과","바나나","배"))
  2. A[1:2,1:2] # 1~2행, 1~2열
  3. A[1:3,] # 1~3행 추출
  4. A[-1,] # 1행 제외 추출
  5. A[,-c(2,3)] #2~3열 제외 추출
  6. A$과일 or A[,'과일'] # 과일열 추출
  7. A$과일[2]
- 참고 : data.frame(벡터1,벡터2, ...), 동일길이 벡터를 주로 활용

리스트 생성 및 추출

- 리스트 생성 및 추출
  1. L <- list(x = 1:3, y = c("A","B","C")
  2. L$x
  3. L[1]
  4. L[[1]]

대입연산자

- 대입연산
  - A <- 1:10
  - A[1] <- 4
  - A[1:3] <- 4 # Broadcasting
  - A[1:3] <- 3:5
  - A <- matrix(1:8,nrow=2)
  - A[,2] <- c(4,1)
  - A[1:2,1:2] <- 2
  - A[1:2,1:2] <- matrix(c(1,2,3,4),nrow=2)

펙터(factor)

- 특정 수준 값만을 가질 수 있는 데이터 타입
  1. A <- factor(c("바나나","사과","오렌지"))
  2. A[3] <- "Hello“ # Error
  3. A[3] <- "오렌지“
  4. A <- data.frame(숫자=c(1,2,3),과일= c("사과","바나나","배"))
  5. A <- data.frame(숫자=c(1,2,3),과일= c("사과","바나나","배"), stringsAsFactors=FALSE)

조건문

- 조건문 if

1. if(조건1){
2. 코드1
3. } else if(조건2)
4. 코드2
5. } else{ # 그외
6. 코드3
7. }

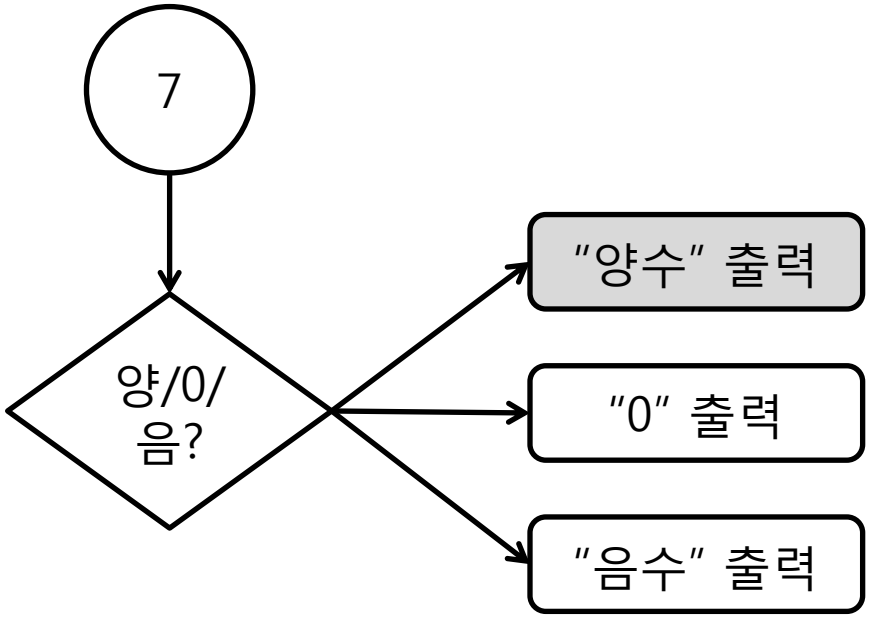

조건문

- X가 7일때 양수/음수/0 판단 조건문 프로그램

```
1. X <- 7
2. if(X>0){
3.    cat("양수")
4. } else if(X==0){
5.    cat("0")
6. } else{
7.    cat("음수")
8. }
```

연습문제

- 점수를 입력받아 성적을 판단 프로그램
  - 90 이상 수
  - 80~90 이하 우
  - 70~80 이하 미
  - …
- 홀짝 판단하는 프로그램

반복문

- 반복문
  - for : 일반적으로 가장 많이 사용
  - while : 무한루프, while(1){ }, while(TRUE){} 형태
  - repeat

for문

- for 문
  1. for(반복변수 in 객체(보통 벡터)){
  2. 코드
  3. }

for문

- 벡터값 1개씩 출력

```
1.  fruits <- c('사과','배','귤','참외','자두')
2.  for(fruit in fruits){
3.    print(fruit)
4.  }
```

fruits <- c('사과','배','귤','참외','자두')

인덱스	1	2	3	4	5
값	사과	배	귤	참외	자두

for문

- 1에서 100까지의 합

```
1. sum <- 0
2. for(i in 1:100)
3. {
4.     sum <- sum + i
5. }
6. print(sum)
```

1:100 벡터

인덱스	1	2	3	…	100
값	1	2	3	…	100

for문

- 구구단 출력

```
1. for(i in 1:9){
2.     for(j in 1:9){
3.         print(paste(i, "*", j, "=", i*j,sep=""))
4.     }
5. }
```

while문

- 1에서 100까지의 합

```
1. i <- 1
2. sum <- 0
3. while (i <= 100){
4.     sum <- sum + i
5.     i <- i + 1
6. }
7. print(sum)
```

while문

- 구구단 출력

```
1.  i <- 1
2.  while (i <= 9){
3.    j <- 1
4.    while (j <= 9){
5.      cat(i, "*", j, "=", i*j,"₩n",sep="")
6.      j <- j + 1
7.    }
8.    i <- i + 1
9.  }
```

반복문 제어

- break : 루프 탈출

```
1. for(i in 1:10){
2.     if(i %% 2 == 0){
3.         break
4.     }
5.     print(i)
6. }
```

반복문 제어

- next : 반복문 블록의 수행을 중단하고 다음 반복을 시작

```
1. for(i in 1:10){
2.     if(i %% 2 == 0)
3.         next
4.     print(i)
5. }
```

연습문제

- “exit”가 입력될 때 까지 무한 루프를 수행하는 코드를 작성
- 1+2+3+…+N이 150이상이 되는 첫 N을 구하는 코드를 작성
- 1~9까지 제곱합 출력 (1+4+9…)

함수

- 함수 : Function
  - 함수정의 : 함수 <- function(인자1,인자2,…) { 내용 }
  - 함수호출 : 함수(인자1,인자2,…)

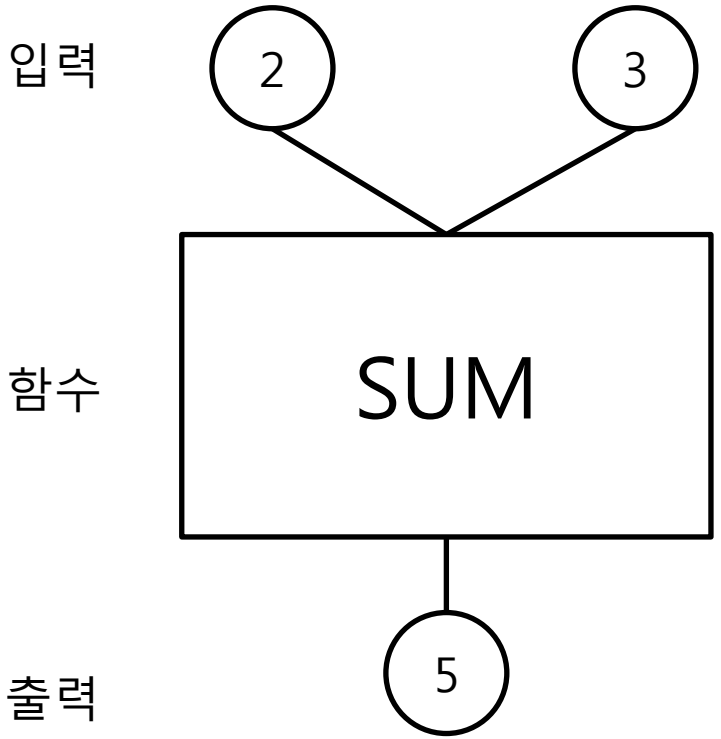


```
> sum(2,3)
[1] 5
```

함수

- 2개의 값을 입력 받아 평균을 내는 함수
  - 함수정의 : 함수 <- function(인자1,인자2,…) { 내용 }

```
1. ave_two <- function(n1,n2)
2. {
        return (n1 + n2)
3. }
```

- 함수호출 : 함수(인자1,인자2,…)

```
1. ave_two(2,3)
```

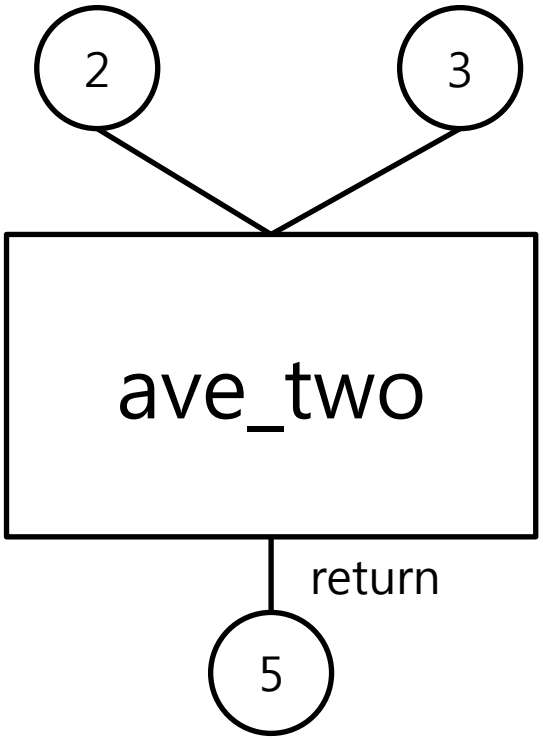

연습문제

- 2개의 값을 입력 받아 큰 수 출력하는 함수 구현
- 2개의 값을 입력 받아 그 사이에 해당하는 값을 더해주는 함수 구현 (두수도 포함)
- 3개의 값을 입력 받아 1번째 수 + 2번째 수 – 3번째 수를 수행하는 함수 구현

그외 주요내용

- names : 벡터에 이름 부여
- colnames : 열 이름
- rownames : 행 이름
- NULL/NA 처리 : is.na(객체), is.null(객체)
- which : 인덱스 위치
- paste : 문자열을 붙일때
- unlist
- sort : 정렬
- order : 정렬 색인
- ….

R 통계량 구하기

Maths Functions

`log(x)`	Natural log.	`sum(x)`	Sum.
`exp(x)`	Exponential.	`mean(x)`	Mean.
`max(x)`	Largest element.	`median(x)`	Median.
`min(x)`	Smallest element.	`quantile(x)`	Percentage quantiles.
`round(x, n)`	Round to n decimal places.	`rank(x)`	Rank of elements.
`signif(x, n)`	Round to n significant figures.	`var(x)`	The variance.
`cor(x, y)`	Correlation.	`sd(x)`	The standard deviation.

R 통계량 구하기

- 통계량 구하기

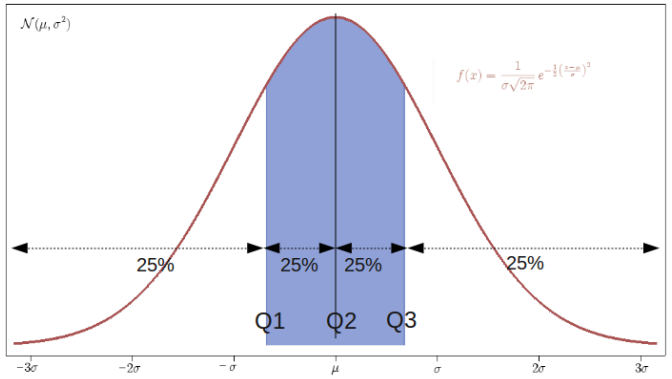

1. score = c(50,60,100,95,85)
2. mean(score) # 평균
3. median(score) # 중앙값
4. max(score) # 최고값
5. quantile(score) # 4분위수, IQR = Q3 – Q1
6. which(score == 95) # 인덱스

연습문제

- 성적표
  - kor : 90, math : 95, hist : 80, ps : 70, music : 70
- 문제
  - 점수를 score 벡터에 저장
  - names를 이용해 제목 부여
  - 평균, 중앙값, 표준편차, 최고점 과목

apply 함수

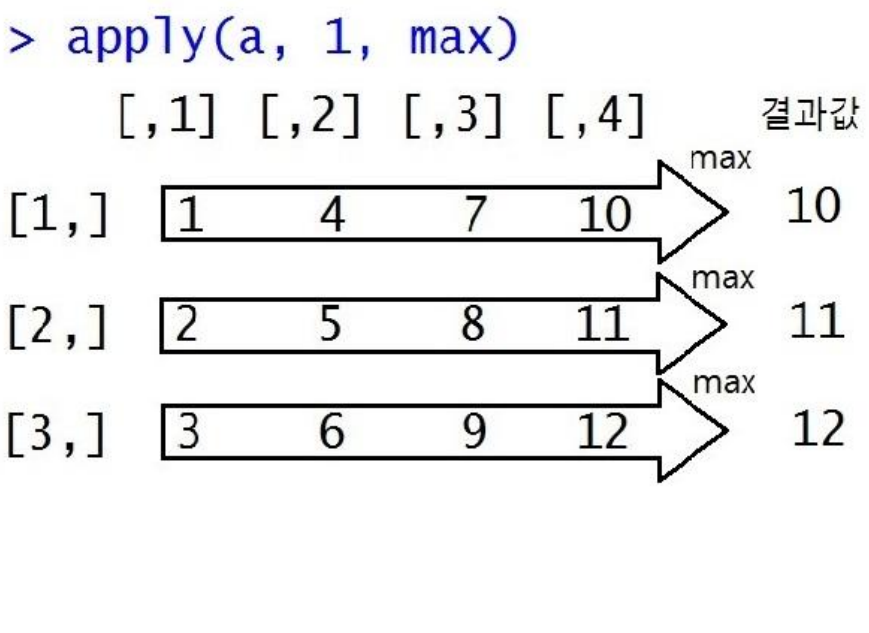

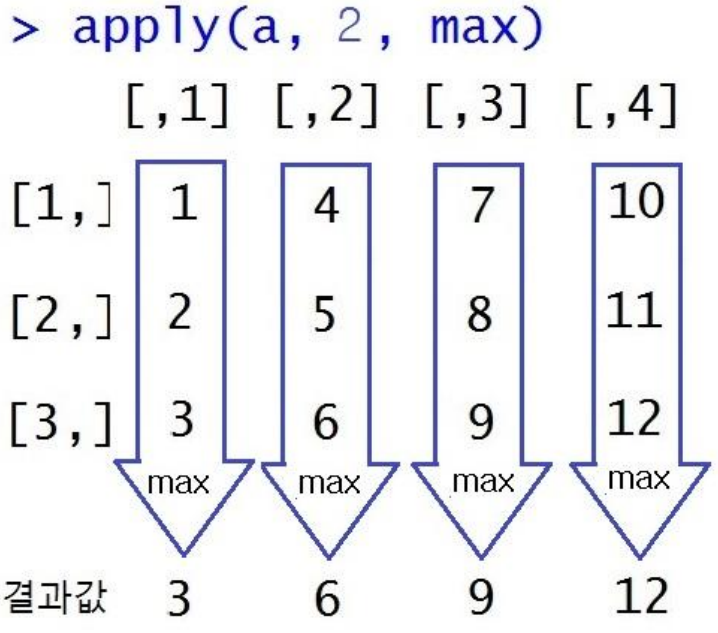

- apply(객체, 1 or 2, 함수)
- 1 : 행 , 2 : 열

출처 : https://issactoast.com/53

연습문제

- 1~25로 이루어진 5 * 5 행렬 생성
- 문제
  - 행 합, 열 합
  - 행 평균, 열 평균
  - 행 최대값, 열 최대값

R 시각화

SET GRAPHICAL PARAMETERS

*the following can **only** be set with* `par()`

par (...)

multiple plots	`mfcol = c(nrow,ncol)` `mfrow = c(nrow,ncol)`	*plot margins (outer)*	`oma = c(bottom, left, top, right)` default: `c(0, 0, 0, 0)` lines
plot margins	`mar = c(bottom, left, top, right)` default: c(5.1, 4.1, 4.1, 2.1) lines	*query x & y limits*	`par ("usr")`

CREATE A NEW PLOT

Bar charts	**`barplot`**`(height, ...)`	**Histograms**	**`hist`**`(x, ...)`
bar labels	`names.arg =`	*breakpts*	`breaks =`
border	`border =`		
fill color	`col =`	**Line charts**	**`plot`**`(x, type = "l")`
horizontal	`horiz = TRUE`	*line type*	`lty =` "blank"|0 "solid"|1 "dashed"|2 "dotted"|3
Box plots	**`boxplot`**`(x, ...)`	*line width*	`lwd =`
horizontal	`horizontal = TRUE`		
box labels	`names =`	**Scatterplots**	**`plot`**`(x, ...)`
Dot plots	**`dotchart`**`(x, ...)`	*symbol*	`pch =`
dot labels	`labels =`		

REMOVE

axis labels	`ann = FALSE`
axis, tickmarks, and labels	`xaxt = "n"` `yaxt = "n"`
plot box	`bty = "n"`

NOTE: Many of the parameters here can be also be set in `par()`*. See R help for more options.*

ADJUST

allow plotting out of plot region	`xpd = TRUE`
aspect ratio	`asp =`
axis limits	`xlim =, ylim =`
axis lines to match axis limits	`xaxs = "i"` , `yaxs = "i"` *(internal axis calculation)*

ADD TEXT

location

axis labels	`xlab =, ylab =`
subtitle	`sub =`
title	`main =`

style

font face	`font = 1` *(plain)* 2 *(bold)* 3 *(italic)* 4 *(bold italic)*
font family	`family = "serif"` "sans" "mono"

size

(magnification factor)

all elements	`cex =`
axis labels	`cex.lab =`
subtitle	`cex.sub =`
tick mark labels	`cex.axis =`
title	`cex.main =`

position

text direction	`las = 1` (horizontal)
justification	`adj = 0 .5 1` (left, center, right)

ADD TO AN EXISTING PLOT

Add new plot [*any plot function*] (..., `add = TRUE`)

ex. `barplot(x, add = TRUE)`

Axes	**`axis`** *(side,...)*
location	`side = 1 2 3 4` (bottom, left, top, right)
tick mark:	
labels	`labels =`
location	`at =`
remove	`tick = FALSE`
rotate text	`las = 1` (horizontal)
Axis labels	**`mtext`** *(text,...)*
location	`side = 1 2 3 4` (bottom, left, top, right)
lines to skip	`line =` *(from plot region, default = 0)*
position	`at =` *x or y-coord* (depending on side)
justification	`adj = 0 .5 1` (left, center, right)

Lines	**`lines`** *(x,...)*
line style	`lty =`
line width	`lwd =`
color	`col =`
Points	**`points`** *(x,...)*
symbol	`pch =`

color	`col =`
fill color	`bg =` `(pch: 21-25 only)`
Text	**`text`** *(x, y, text,...)*
position (rel. to x,y)	`pos = 1 2 3 4` (below, left, above, right) (default=center)
Title	**`title`** *(main,...)*
axis labels	`xlab =, ylab =`
subtitle	`sub =`
title	`main =`

Joyce Robbins, joycerobbins1@gmail.com

http://publish.illinois.edu/johnrgallagher/files/2015/10/BaseGraphicsCheatsheet.pdf

R 시각화

- Scatter Plot

1. x <- c(1,2,3,4,5)
2. y <- c(1,4,3,5,9)
3. plot(x,y)
4. plot(x,y,main="title“)
5. plot(x,y,font=3, main="title")
6. plot(x,y,font.main=3, main="title")
7. plot(x,y,xlim=c(1,5),main="title")
8. plot(x,y,font.main=3,xlim=c(1,5),main="title",ann=FALSE)

R 시각화

- Scatter Plot

1. x <- c(1,2,3,4,5)
2. y <- c(1,4,3,5,9)
3. plot(x,y)
4. title(main="title")
5. title(xlab="num")
6. text(3,3, "Hello")

R 시각화

- 히스토그램

1. A <- round(runif(100, min = 0,max = 100),0)
2. hist(A, main="")
3. title("histogram")

R 시각화

- Boxplot

1. A <- round(runif(100, min = 0,max = 100),0)
2. boxplot(A)
3. title(main="boxplot")
4. title(xlab="Hello")
5. axis(4)
6. lines(c(1,1),c(30,50))

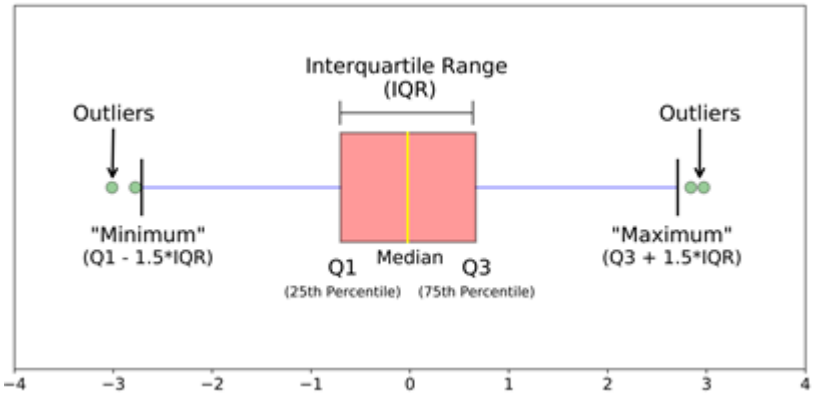

R 활용사례 : iris 데이터 분석

변수명	변수설명
Species	붓꽃의 종. setosa, versicolor, virginica 세 가지 값 중 하나
Sepal.Width	꽃받침의 너비
Sepal.Length	꽃받침의 길이
Petal.Width	꽃잎의 너비
Petal.Length	꽃잎의 길이

- iris_analysis.R 참조

R 활용사례 : mtcars 데이터 분석

변수명	변수설명
mpg	연비 (Miles per Gallon)
cyl	실린더 개수
disp	배기량
hp	마력
drat	후방차축 비율
wt	무게
qsec	1/4 마일에 도달하는데 걸린 시간
vs	엔진 (0 : V engine 1 : Straight engine)
am	변속기 (0 : 자동, 1 : 수동)
gear	기어 개수?
carb	기화기(카뷰레터) 개수

- mtcars_analysis.R 참조